

Báo cáo chi tiết công việc ngày 14/05/2026

Trong ngày 14/05/2026, dự án **HybridMamba Anomaly Detection** đã được triển khai một loạt các cải tiến quan trọng, tập trung vào việc tổng quát hóa khả năng xử lý đa dữ liệu (Multi-dataset), tối ưu hóa quy trình đánh giá và hoàn thiện tài liệu kỹ thuật.

1. Tóm tắt các thay đổi trong ngày

Dưới đây là các thay đổi:

- **refactor: abstract dataset into generic BearingDataset:** Thực hiện tái cấu trúc mã nguồn để tách biệt logic xử lý dữ liệu ổ bi thành một class dùng chung. Thêm hỗ trợ `MultiBearingDataset` cho phép huấn luyện mô hình trên nhiều tập dữ liệu cùng lúc và chạy benchmark tự động.
- **fix: adjust figure scaling and layout in LaTeX:** Điều chỉnh tỷ lệ hình ảnh và định dạng layout trong tài liệu LaTeX để đảm bảo tính thẩm mỹ và chuẩn xác cho bài báo nghiên cứu.
- **feat: add full lifecycle visualization tool:** Triển khai công cụ trực quan hóa toàn bộ vòng đời của ổ bi. Cập nhật pipeline xử lý dữ liệu cho các tập dataset, cải thiện độ ổn định của quy trình tiền xử lý.
- **feat: add HybridMamba++ technical paper:** Hoàn thiện dự thảo bài báo kỹ thuật cho mô hình HybridMamba++ và tích hợp kịch bản đánh giá.

2. Các thay đổi và cải tiến chi tiết

Ngoài các commit trên, phiên làm việc hiện tại đã thực hiện các bước tối ưu hóa cấu hình và phát triển công cụ phân tích mới:


A. Cấu hình Huấn luyện và Kiểm thử đa dữ liệu

- **Cập nhật `configs/default.yaml` :**
 - Thiết lập huấn luyện mô hình trên tổ hợp dữ liệu **B02** và **B05**.
 - Sử dụng các bộ dữ liệu còn lại (**B01, B03, B04**) làm tập kiểm thử để đánh giá khả năng tổng quát hóa của mô hình trên các đối tượng lạ.
 - Điều chỉnh `skip_ratio` xuống **0.05** (5%) để tận dụng nhiều dữ liệu hơn từ giai đoạn đầu của vòng đời ổ bi.

B. Phát triển Notebook Đánh giá Đa ổ bi (multi_bearing_lifecycle.ipynb)

Đã tạo một công cụ phân tích mạnh mẽ dưới dạng Jupyter Notebook giúp đánh giá mô hình trên diện rộng:

- **Hỗ trợ đa dữ liệu:** Tự động lặp qua và đánh giá trên tất cả các ổ bi (B01 đến B05).
- **Trực quan hóa xu hướng:** Vẽ biểu đồ kết hợp giữa **RMS (Năng lượng tín hiệu)** và **MSE (Anomaly Score)**.



Hình 1: Trực quan hóa vòng đời đa ổ bi

- **Tích hợp ngưỡng POT (Peak-Over-Threshold):**
 - Triển khai thuật toán xác định ngưỡng động dựa trên lý thuyết giá trị cực trị.

- Ngưỡng được tính toán dựa trên đặc tính riêng của từng ổ bi trong giai đoạn khỏe mạnh (20% dữ liệu đầu tiên sau startup).
- Giúp xác định chính xác thời điểm mô hình coi tín hiệu là bất thường so với baseline.
- **Tối ưu hóa kiến trúc:** Đồng bộ hóa tham số `SKIP_RATIO` với class `BearingDataset` của dự án, đảm bảo tính nhất quán trong toàn bộ pipeline.

3. Kết quả Huấn luyện và Đánh giá thực tế (Thử nghiệm 5 Epochs)

💡 Ghi chú:

Do hạn chế về tài nguyên GPU hiện tại, các mô hình mới chỉ được huấn luyện thử nghiệm trong **5 Epochs**. Kết quả cho thấy mô hình vẫn đang trong đà hội tụ và hoàn toàn có thể đạt độ chính xác cao hơn nếu tăng số lượng Epochs kết hợp với cơ chế **Early Stopping** trong các lần chạy sau.

Dưới đây là kết quả thu được từ quá trình huấn luyện thực tế trên tổ hợp B02 + B05:

A. So sánh quy mô mô hình

Model Name	Parameters	Ghi chú
Mamba1-Hybrid	4,491,478	Tối ưu hóa cho thiết bị công nghiệp.
MambaTS-Official	8,457,280	Quy mô lớn hơn, độ phức tạp tính toán cao hơn.

B. Hiệu năng mô hình Mamba1-Hybrid (Sau 5 Epochs)

- **Thời gian huấn luyện:** 495.61 giây (Cuda GPU).
- **Độ mất mát (Val Loss):** Giảm từ 0.1445 xuống **0.1420**.
- **Chỉ số AUPRC:** **0.9924** (Độ tin cậy cực cao).
- **So sánh các phương pháp xác định ngưỡng (Thresholding):**

Phương pháp	F1-Score	Mục tiêu sử dụng
3-Sigma	0.9531	Công nghiệp (Tính toán nhanh, đơn giản)
Robust	0.9541	Công nghiệp (Kháng nhiễu tốt, tốc độ cao)

Phương pháp	F1-Score	Mục tiêu sử dụng
POT (SOTA)	0.9543	Nghiên cứu Paper (Độ chính xác cao nhất)
Optimal	0.9547	Baseline tham chiếu (Lý tưởng)

- **Độ trễ (Latency): 0.0381 ms/mẫu** (Đảm bảo khả năng chạy Real-time).

C. So sánh với MambaTS-Official

- **MambaTS-Official** đạt F1 (POT) là **0.9549** nhưng với lượng tham số gấp đôi (8.45M) và độ trễ cao hơn đáng kể. Điều này khẳng định sự hiệu quả của kiến trúc **Hybrid** trong việc cân bằng giữa hiệu năng và tài nguyên.

4. Kết luận và Hướng đi tiếp theo

- Hệ thống hiện tại đã có khả năng **huấn luyện đồng thời trên nhiều ổ bi**, giúp mô hình học được không gian trạng thái "khỏe mạnh" tổng quát hơn.
- Mô hình **Hybrid** cho thấy ưu thế vượt trội về tốc độ và quy mô (nhẹ hơn ~2 lần so với bản gốc) trong khi vẫn đạt được các chỉ số F1 và AUPRC rất ấn tượng (>95%).
- **Tiềm năng tối ưu:** Do giới hạn GPU hiện tại nên mới chỉ huấn luyện 5 epochs, tuy nhiên xu hướng hội tụ cho thấy mô hình vẫn có thể học tiếp. Trong tương lai, việc tăng số lượng **Epochs** lên cao hơn (30-50) kết hợp với **Early Stopping** hứa hẹn sẽ đẩy các chỉ số F1/AUPRC lên mức tiệm cận tuyệt đối.
- Ngưỡng POT giúp giảm thiểu tỉ lệ báo động giả (False Alarms) bằng cách thích ứng với mức nhiễu nền của từng thiết bị cụ thể.